

ML TERM PROJECT

소리만으로 히트곡을 예측할 수 있을까?

Spotify 오디오 피쳐 기반 인기곡 분류



114,000곡



13개 피쳐



3개 모델

왜 이 문제인가?

Spotify에는 매일 6만 곡이 새로 올라온다.

하지만 대부분의 곡은 거의 재생되지 않는다.

*" 유명세 마케팅 없이,
소리 자체만으로 인기곡을 구분할 수 있는가? "*

Spotify는 모든 곡의 음향 특성을
자동 수치화 → 발매 전에도 계산 가능!

1억+

Spotify 전체 트랙 수

60,000

하루 신규 업로드 곡 수

11%

인기곡 비율 (이 데이터셋)

114,000곡의 소리를 수치로

danceability

춤추기 적합한 정도

0 - 1

energy

얼마나 강렬한가

0 - 1

loudness

평균 음량

dB

instrumentalness

보컬 없이 악기만?

0 - 1

acousticness

어쿠스틱 악기 비율

0 - 1

valence

밝고 긍정적인 분위기

0 - 1

tempo

빠르기

BPM

explicit

선정적 가사 여부

0 / 1

⚠ 타겟: popularity ≥ 60이면 인기곡(1), 미만이면 비인기곡(0) — 전체의 약 11%만 인기곡 → 클래스 불균형!

어떻게 풀었나 — 3단계 모델 비교

BASELINE

Logistic Regression

가장 단순한 선형 분류기.
성능의 하한선 기준점 역할.

앙상블

Random Forest

수백 개 결정 트리를 합산.
비선형 패턴 학습 가능.

BEST

XGBoost

오류에 집중하며 순차 개선.
하이퍼파라미터 자동 탐색.

⚠ 실험 중 발견한 문제


초기 결과: Accuracy 89%, F1 = 0.00
→ 모델이 모든 곡을 "비인기"로만 예측!
→ 해결: 인기곡에 8배 더 높은 가중치 부여

💡 핵심 교훈

정확도(Accuracy)만 믿으면 안 된다.
F1 Score가 불균형 데이터의 진짜 성능 지표.
XGBoost 60번 실험 → 최적 파라미터 탐색.


실험 결과 — XGBoost가 가장 좋았다

Model	Test Accuracy	Test F1	Test AUC
Logistic Regression	0.543	0.242	0.644
Random Forest (default)	0.888	0.073	0.718
Random Forest (tuned)	0.617	0.277	0.703
XGBoost (default)	0.765	0.275	0.701
★ XGBoost (tuned)	0.745	0.294	0.722



F1 Score: 인기곡을 얼마나 잘 찾아내는가 (0~1, 높을수록 좋음) | AUC: 랜덤 추측(0.5)보다 얼마나 더 잘 구분하는가 | XGBoost(tuned) AUC 0.722 → 랜덤 대비 +22%p

무엇이 인기를 결정하는가?



🏆 1위 explicit (0.140)

선정적 가사 여부
→ 힙합·R&B 장르 강세 반영
보컬+강렬한 현대 음악 = 인기

🥈 2위 instrumentalness (0.098)

보컬 없는 정도
→ 순수 악기 곡(클래식·재즈)은
스트리밍에서 비인기 경향

🥉 3위 loudness (0.080)

음량 크기
→ 크고 강한 곡이 유리
조용한 어쿠스틱 곡은 불리

한계와 실패 분석

오분류가 집중되는 경우

경계선상 곡들

popularity 45~65점
→ 인기/비인기 구분 어려운 회색지대

장르 혼재 문제

클래식·재즈의 오디오 피처가
팝·힙합과 완전히 다른 패턴

Val-Test 갭

XGBoost Val F1 0.593 → Test 0.294
하이퍼파라미터 과적합 징후

근본적 한계

오디오 피쳐만으로 설명 못하는 것들

- 아티스트 팬덤 크기
- 마케팅·프로모션 비용
- 앨범 발매 시기
- 소셜미디어 바이럴

최종 평가

F1 = 0.294, AUC = 0.722
실서비스엔 부족하지만, 랜덤(0.5)보다
유의미하게 높은 예측력 확인

결론

✓ 오디오 피쳐만으로도 랜덤 대비 유의미한 예측 가능 (AUC 0.722)

✓ explicit-instrumentalness가 핵심 인기 결정 인자

⚠ 오디오 외 정보(아티스트·트렌드) 없이는 근본적 한계 존재

Future Work

- 아티스트 팔로워 수 피쳐 추가
- 장르별 분리 모델 학습
- Regression으로 전환
- Raw 오디오 → CNN 학습
- SMOTE 오버샘플링 적용

" 소리 자체는 인기의 일부만 설명한다. 하지만 그 일부조차도 의미 있는 신호를 담고 있다. "